



FACULTÉ DES SCIENCES DHAR EL MAHAZ
UNIVERSITÉ SIDI MOHAMED BEN ABDELLAH

Projet tutoré

Intitulé:

Collaborative filtering approach in recommender systems

Présenté par:

- El Yagouby Mohamed Amine
- Taghzouti Othmane

Encadré par:

- Pr. Nfaoui El Habib

Soutenu le 28 mai 2022

Le plan

I - Contexte général du projet



II - Systèmes de recommandations basés sur le filtrage collaboratif



III - L'application web SmartRecommender

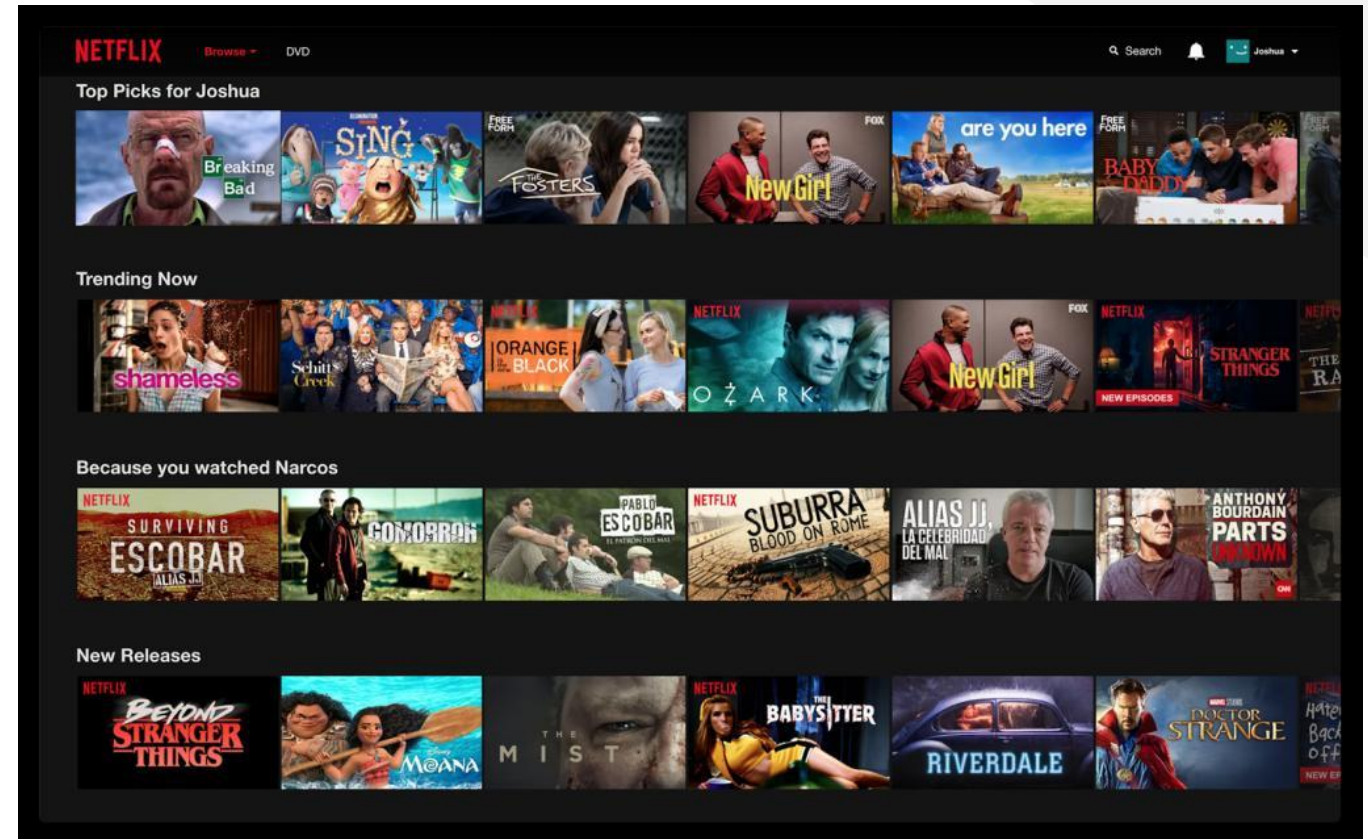
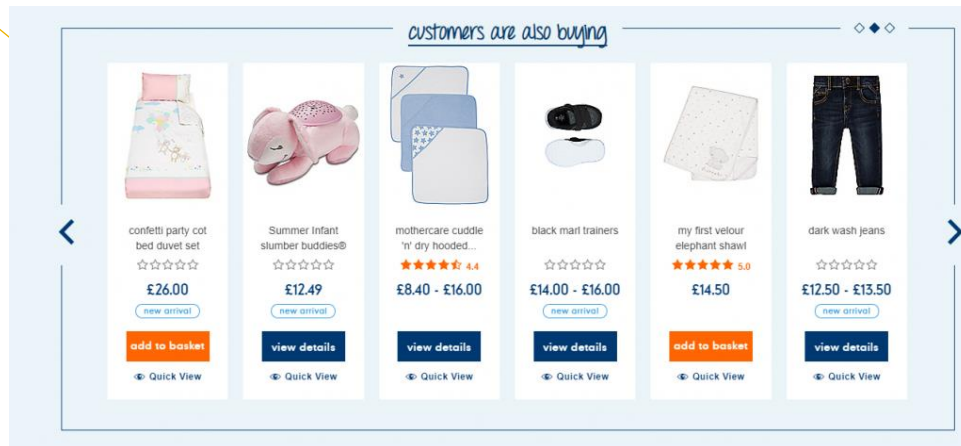




Contexte général du projet


Aperçu sur les systèmes de recommandation

- Guider l'utilisateur dans ses choix
- Maximiser les profits (Amazon 5^{ème} plus grande entreprise au monde, 70% des visionnages sur Youtube...)

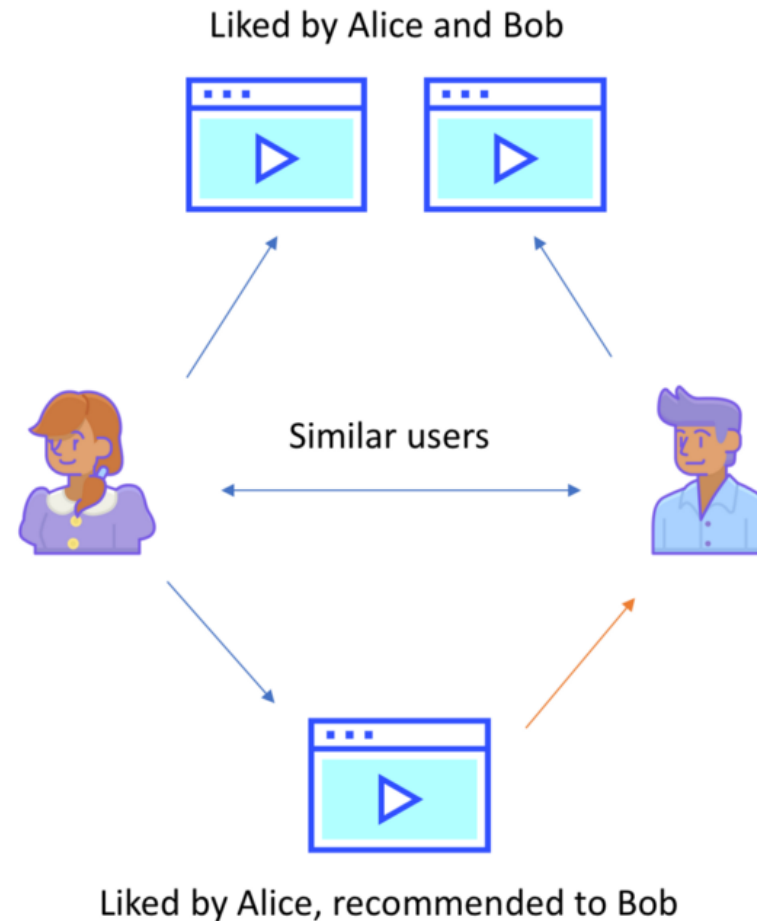


Principe de fonctionnement

Content-based filtering



Collaborative filtering



Problématique

- **Comment peut-on construire un système de recommandation?**
 - **Laquelle des deux méthodes est mieux adaptée?**
- **Comment peut-on valider le résultat de notre système de recommandation?**

Filtrage collaboratif:

- Pas de connaissance approfondie requise
 - Data à utiliser moins volumineuse
 - L'effet « surendipitous »

Objectifs du projet


- Étude du filtrage collaboratif avec ses différents modèles
 - Comparaison et analyse de ces modèles
- Réalisation d'une application web de recommandation avec des datasets variées

Task Name	Duration	Start	Finish	Predecessors	Resource Names	March 2022							April 2022					May 2022						
						21	26	03	08	13	18	23	28	02	07	12	17	22	27	02	07	12	17	
Building background knowledge	21 days	28/02/22	21/03/22		Amine El Yagouby;Othmane Taghzouti																			
Discovery of artificial intelligence and machine learning	7 days	28/02/22	07/03/22																					
Studying of machine learning basic algorithms	10 days	07/03/22	17/03/22	2																				
Learning basics of Python	2 days	17/03/22	19/03/22	3																				
Familiarization with Google Colab and Jupyter	2 days	19/03/22	21/03/22	4																				
Learning about recommender systems	12 days	21/03/22	02/04/22		Amine El Yagouby;Othmane Taghzouti																			
Recommender Systems approaches	12 days	21/03/22	02/04/22	5																				
Singular Value Decomposition mathematical aspects	5 days	21/03/22	26/03/22	5																				
Elaborating the algorithms	22 days	02/04/22	24/04/22		Amine El Yagouby;Othmane Taghzouti																			
Elaboration of some model based approaches	10 days	02/04/22	12/04/22	8;7																				
Elaboration of some memory based approaches	10 days	12/04/22	22/04/22	10																				
Testing multiple datasets	2 days	22/04/22	24/04/22	11;10																				
Crossvalidating results	1 day	22/04/22	23/04/22	10;11																				
Defining the use-case diagram	1 day	24/04/22	25/04/22	9																				
Developping the web application	16 days	24/04/22	10/05/22	9	Amine El Yagouby																			
Preparing the report	16 days	24/04/22	10/05/22	9	Othmane Taghzouti																			
Writing the report	11 days	24/04/22	05/05/22																					
Designing the images	2 days	24/04/22	26/04/22																					
Checking and validating	5 days	05/05/22	10/05/22	17																				
Final steps	7 days	10/05/22	17/05/22	19	Amine El Yagouby;Othmane Taghzouti																			
Reviewing the application	7 days	10/05/22	17/05/22																					
Preparing the presentation	5 days	10/05/22	15/05/22																					



Le filtrage collaboratif

Le filtrage collaboratif



Data utilisée

Matrice utilisateur-objet (User-item matrix)

Objets



userId movieId ratings

196 242 3

186 302 3

22 377 1

244 51 2

166 346 1

Utilisateurs



4

4

5

5

5

4

5

4

?

5

?

3

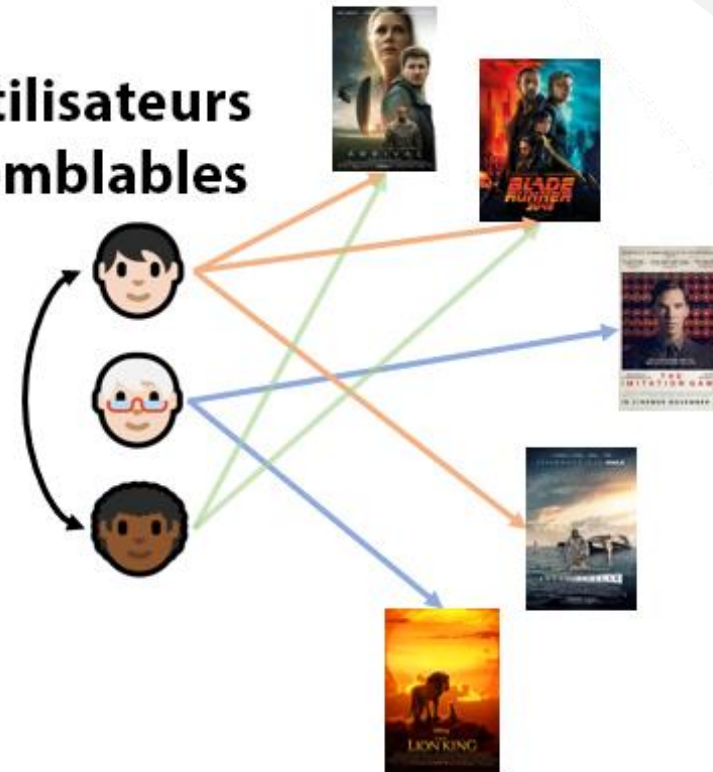
?

Les types du filtrage collaboratif: memory based (User based)

$$\hat{r}_{u,i} = \text{aggr}_{v \in N_i(u)} r_{v,i}$$

$$\hat{r}_{u,i} = \frac{\sum_{v \in N_i(u)} \text{sim}(u, v) \cdot r_{v,i}}{\sum_{v \in N_i(u)} \text{sim}(u, v)}$$

Utilisateurs
semblables




Les types du filtrage collaboratif: memory based (Item based)

$$\hat{r}_{u,i} = \text{aggr}_{j \in N_u(i)} r_{u,j}$$

$$\hat{r}_{u,i} = \frac{\sum_{j \in N_u(i)} \text{sim}(i, j) \cdot r_{u,j}}{\sum_{j \in N_u(i)} \text{sim}(i, j)}$$

Objets semblables




Mesure de similarité

$$\text{cos similarity}(u, v) = \frac{\sum_{i \in I_{uv}} r_{ui} r_{vi}}{\sqrt{\sum_{i \in I_u} r_{ui}^2 \sum_{i \in I_v} r_{vi}^2}}$$


$$\text{msd similarity}(u, v) = \frac{1}{\frac{1}{|I_{uv}|} \sum_{i \in I_{uv}} (r_{ui} - r_{vi})^2 + 1}$$

Model based


Décomposition en valeurs singulières (SVD)




M
 $m \times n$



U_r
 $m \times r$




Σ_r
 $r \times r$



V_r^{*}
 $r \times n$

$$\hat{r}_{ui} = U_u V_i^T$$

Utilisateurs



Objets



4				5	
4	5		5		
	5		4		3
5	4				

Facteurs latents

Popularité

Durée

?	?
?	?
?	?
?	?

 U 

?	?	?	?	?	?
?	?	?	?	?	?


 $X \approx$

4				5	
4	5		5		
	5		4		3
5	4	?	?	?	?

Model based

Minimisation de la fonction objective

$$\min_{p,q} \sum_{(u,i) \in K} (r_{ui} - U_u V_i^T)^2 + \lambda (\|U_u\|^2 + \|V_i\|^2)$$



Validation des modèles de prédiction

- Mesure de l'écart entre les scores estimés et les scores réels (non utilisés dans la construction des modèles) grâce aux relations suivantes

L'erreur absolue moyenne (MAE)
Mean Absolute Error

$$MAE = \frac{1}{|\hat{R}|} \sum_{\hat{r}_{ui} \in \hat{R}} |r_{ui} - \hat{r}_{ui}|$$

L'erreur quadratique moyenne (RMSE)
Root Mean Squared Error

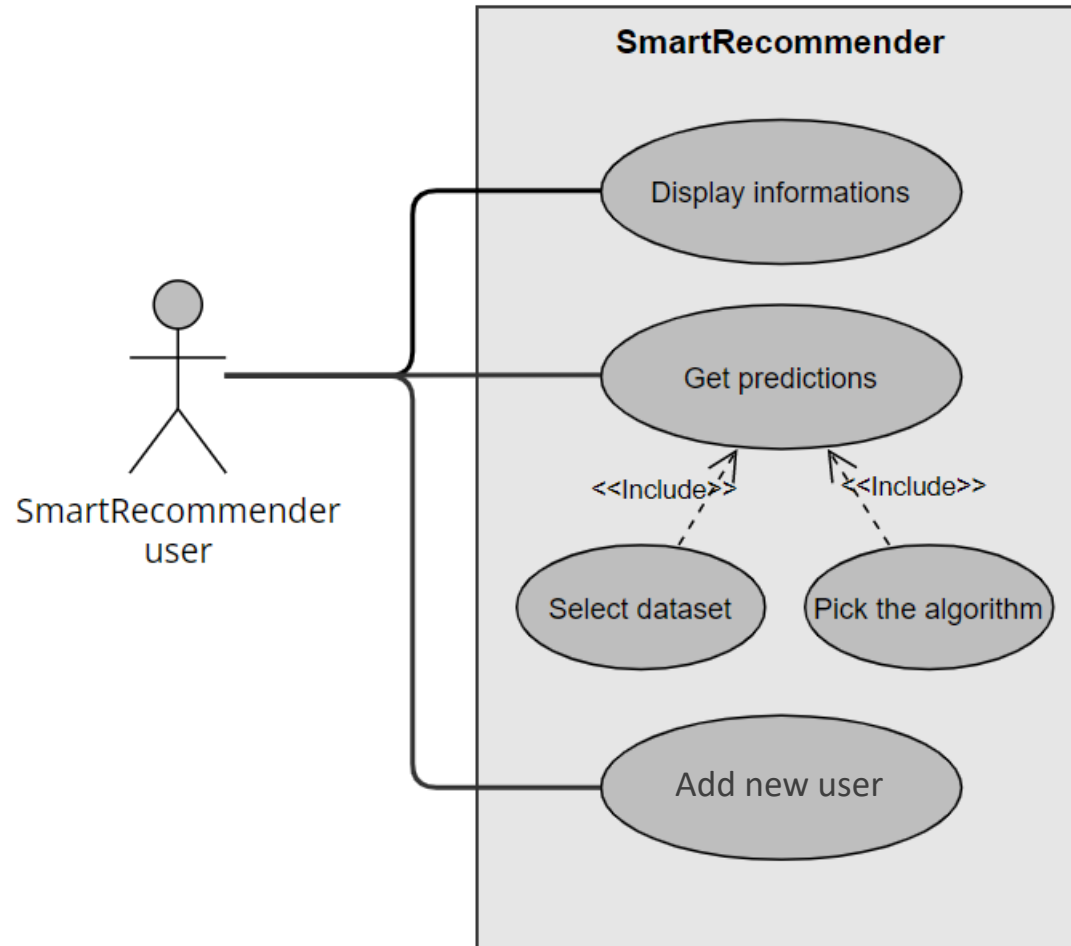
$$RMSE = \sqrt{\frac{1}{|\hat{R}|} \sum_{\hat{r}_{ui} \in \hat{R}} (r_{ui} - \hat{r}_{ui})^2}$$



L'application web SmartRecommender

Description de l'application

- Exploiter le travail achevé précédemment au sein de l'étude des différents modèles du filtrage collaboratif
- Construction et test des systèmes de recommandation en utilisant 2 bases de données:
 - Films (MovieLens 1M ratings, 3883 films, 6040 utilisateurs)
 - Livres (GoodBooks 981757 ratings, 10000 livres 53000 utilisateurs)



Les outils principalement utilisés



Python

Langage de programmation qui fournit des outils adaptés à l'apprentissage automatique



Pandas

Librairie de manipulation des données



Django

Framework qui suit l'architecture MVT



Scikit-Surprise

- Librairie orientée spécifiquement à la construction et l'analyse des systèmes de recommandation
- Convient parfaitement à notre projet grâce aux algorithmes de CF qui y sont définis: SVD pour le model-based, KNN inspired pour le memory based

Description

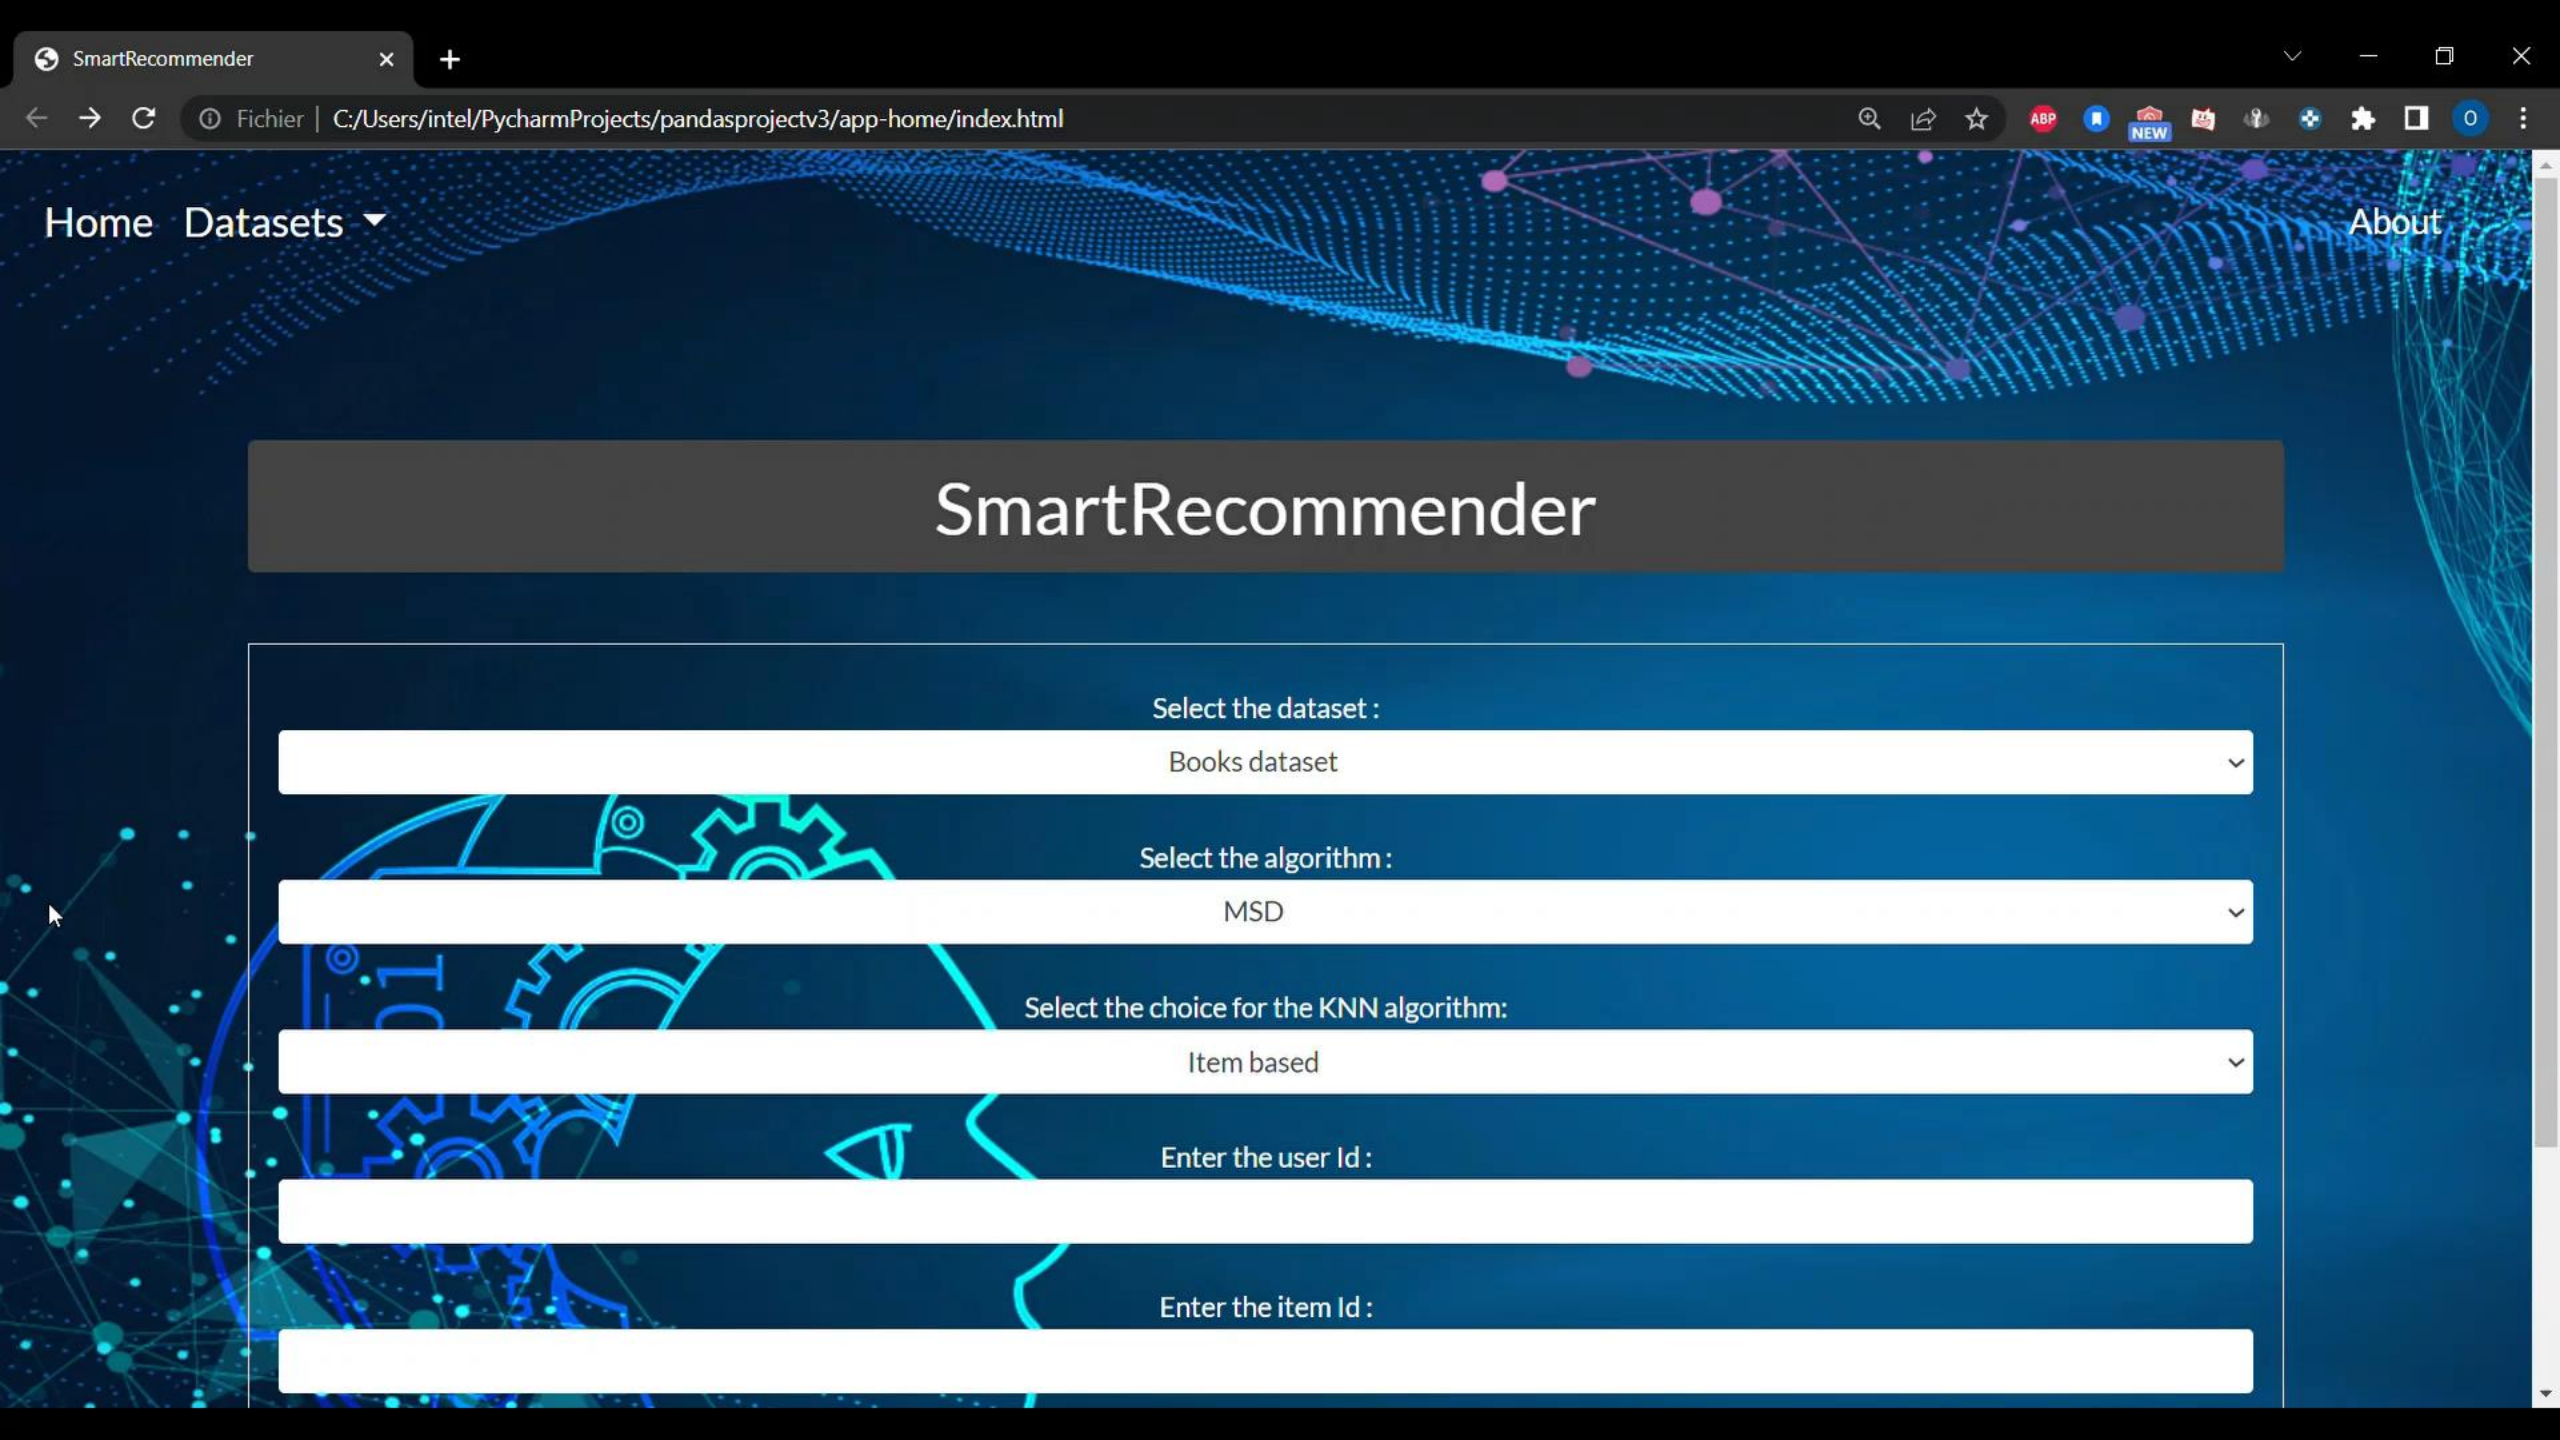
Diagramme CU

Outils

Démonstration

Résultats et
discussion

Démonstration en vidéo



SmartRecommender

Select the dataset :

Books dataset ▾

Select the algorithm :

MSD ▾

Select the choice for the KNN algorithm:

Item based ▾

Enter the user Id :

Enter the item Id :

Description

Diagramme CU

Outils

Démonstration

Résultats et
discussion

Résultats et discussions

SVD

KNN User-based

KNN Item-based

accuracy of the algorithm :

accuracy of the algorithm :

accuracy of the algorithm :

RMSE 0.8809531994362201

MAE 0.6911881047892232

RMSE 0.9283307004098478

MAE 0.7321873820573952

RMSE 0.9178920596660614

MAE 0.7230052919717014

Résultats et discussions

Exemple:

L'utilisateur 5 qui est intéressé par les films du genre comédie et drama

SVD

KNN User-based

KNN Item-based

Top 5 recommandations for the user 5 :

Annie Hall (1977)	Comedy Romance
Do the Right Thing (1989)	Comedy Drama
Manhattan (1979)	Comedy Drama Romance
Magnolia (1999)	Drama
Seventh Seal, The (Sjunde inseglet, Det) (1957)	Drama

Top 5 recommandations for the user 5 :

Gate of Heavenly Peace, The (1995)	Documentary
Schlafes Bruder (Brother of Sleep) (1995)	Drama
Paralyzing Fear: The Story of Polio in America, A (1998)	Documentary
Ulysses (Ulisse) (1954)	Adventure
Smashing Time (1967)	Comedy

Top 5 recommandations for the user 5 :

Open Season (1996)	Comedy
Harlem (1993)	Drama
Condition Red (1995)	Action Drama Thriller
Angela (1995)	Action Drama Thriller
Nueba Yol (1995)	Comedy Drama

Résultats et discussions

- On ne peut pas décider directement le meilleur système de recommandation
- Chaque base de données s'adapte différemment avec un certain algorithme

- └ ➤ Les entreprises divisent les données collectées
 - Testent chaque partie avec un modèle différent
 - Prennent finalement le modèle qui génère un maximum de revenu

The background features a light gray diagonal band running from the top-left towards the bottom-right. To the left of this band is a solid yellow rectangle. Above the band, in the top-right corner, is a dark blue parallelogram. Several thin, parallel diagonal lines in gray, blue, and yellow are scattered across the white background.

Conclusion



Fin

Merci pour votre attention